



深圳大学  
SHENZHEN UNIVERSITY

# 模式识别

## Pattern Recognition

——与计算机视觉  
and Computer Vision

樊超

大数据系统计算技术国家工程实验室@深圳大学

**E-mail:** chaofan996@szu.edu.cn

# 贝叶斯决策

---

- 贝叶斯法则
- 朴素贝叶斯决策
- 最小错误率贝叶斯决策
- 最小损失贝叶斯决策
- 评价指标与ROC曲线
- 贝叶斯参数估计：单维Gaussian估计 ( $\mu$ 未知)
- 贝叶斯参数估计：多维Gaussian估计 ( $\mu$ 未知)
- 关于Gaussian分布

# 贝叶斯法则

---

$$\begin{array}{c} \text{后验} \\ \text{(Posterior)} \\ P(Y|X) \end{array} = \frac{\begin{array}{c} \text{似然} \\ \text{(Likelihood)} \\ P(X|Y) \end{array} \begin{array}{c} \text{先验} \\ \text{(Priors)} \\ P(Y) \end{array}}{P(X)}$$



Rev'd Thomas Bayes (1702–1761)

- 贝叶斯法则：如何根据已知数据  $P(X|Y)$  与先验  $P(Y)$  推断后验  $P(Y|X)$

# 贝叶斯法则——一个简单例子

---

$$\begin{array}{c} \text{后验} \\ \text{(Posterior)} \\ P(Y|X) \end{array} = \frac{\begin{array}{c} \text{似然} \\ \text{(Likelihood)} \\ P(X|Y) \end{array} \begin{array}{c} \text{先验} \\ \text{(Priors)} \\ P(Y) \end{array}}{P(X)}$$

- 问题：教室里有50位同学，判断下位进门的同学是 **男孩** 还是 **女孩**？
  - 令随机变量  $X$  表示同学，  $Y$  表示性别
  - 则先验分布  $P(Y)$  表示教室里的性别分布，如  $P(Y = \text{男}) = \frac{45}{50}$ ,  $P(Y = \text{女}) = \frac{5}{50}$
  - $P(X|Y)$  表示观测数据：这一群是**男孩**，另一群是 **女孩**；  $P(Y|X)$  表示任意新进同学的性别分布
-

# 贝叶斯法则——另一个简单例子

---

例子：流感检测

假设某个城市的人口中，只有 **1%** 患有流感病毒。

现有一种检测方法，已知：

- (1) 如果某人确实患病，检测为阳性的概率为**90%**；
- (2) 如果某人没有患病，检测仍然有**5%**可能性误报为阳性。

现在，已知某人的检测结果为阳性，那么他真正患病的概率有多少？

# 贝叶斯法则——另一个简单例子

---

例子：流感检测

假设某个城市的人口中，只有 **1%** 患有流感病毒。

现有一种检测方法，已知：

- (1) 如果某人确实患病，检测为阳性的概率为**90%**；
- (2) 如果某人没有患病，检测仍然有**5%**可能性误报为阳性。

现在，已知某人的检测结果为阳性，那么他真正患病的概率有多少？

$$X = x^+$$

$$Y = y^+$$

令随机变量  $X \in \{x^+, x^-\}$  表示观测结果， $x^+$  表示阳性， $x^-$  表示阴性

令随机变量  $Y \in \{y^+, y^-\}$  表示真实结果， $y^+$  表示阳性， $y^-$  表示阴性

# 贝叶斯法则——另一个简单例子

---

例子：流感检测

假设某个城市的人口中，只有 **1%** 患有流感病毒。

现有一种检测方法，已知：

- (1) 如果某人确实患病，检测为阳性的概率为**90%**；
- (2) 如果某人没有患病，检测仍然有**5%**可能性误报为阳性。

现在，已知某人的检测结果为阳性，那么他真正患病的概率有多少？

$$X = x^+$$

$$Y = y^+$$

推断  $P(y^+|x^+)$  ?

$$P(Y|X) = \frac{P(X|Y) P(Y)}{P(X)}$$

# 贝叶斯法则——另一个简单例子

例子：流感检测

假设某个城市的人口中，只有 **1%** 患有流感病毒。➡  $P(y^+) = 0.01$

现有一种检测方法，已知：

(1) 如果某人确实患病，检测为阳性的概率为**90%**；➡  $P(x^+|y^+) = 0.9$

(2) 如果某人没有患病，检测仍然有**5%**可能性误报为阳性。➡  $P(x^+|y^-) = 0.05$

现在，已知某人的检测结果为阳性，那么他真正患病的概率有多少？

$X = x^+$

$Y = y^+$

推断  $P(y^+|x^+)$  ?

$$P(Y|X) = \frac{P(X|Y) P(Y)}{P(X)}$$



# 贝叶斯法则——另一个简单例子

---

已知：

- (1) 城市中任意一人，真实患病的概率  $P(y^+) = 0.01$
- (2) 若真实患病，被检测出来患病的概率  $P(x^+|y^+) = 0.9$  ;
- (3) 若没有患病，被检测出来患病的概率  $P(x^+|y^-) = 0.05$  ;

求：检测阳性，真实阳性的概率  $P(y^+|x^+) = \frac{P(x^+|y^+)P(y^+)}{P(x^+)}$

$$P(x^+) = P(x^+|y^+)P(y^+) + P(x^+|y^-)P(y^-) = 0.9 * 0.01 + 0.05 * (1 - 0.01) = 0.0585$$

$$P(y^+|x^+) = \frac{P(x^+|y^+)P(y^+)}{P(x^+)} = \frac{0.9 * 0.01}{0.0585} \approx 0.154$$
$$P(Y|X) = \frac{P(X|Y) P(Y)}{P(X)}$$

# 朴素贝叶斯决策

---

已知:

- (1) 城市中任意一人, 真实患病的概率  $P(y^+) = 0.01$
- (2) 若真实患病, 被检测出来患病的概率  $P(x^+|y^+) = 0.9$  ;
- (3) 若没有患病, 被检测出来患病的概率  $P(x^+|y^-) = 0.05$  ;

决策规则: 若  $P(y^+|x^+) > P(y^-|x^+)$ , 则 🤖 (检测阳性, 推断阳性)

否则,  $P(y^+|x^+) \leq P(y^-|x^+)$ , 则 😊 (检测阳性, 推断阴性)

$$P(y^+|x^+) = \frac{P(x^+|y^+)P(y^+)}{P(x^+)}$$

$$P(y^-|x^+) = \frac{P(x^+|y^-)P(y^-)}{P(x^+)}$$

# 朴素贝叶斯决策

$$\begin{array}{ccc}
 \text{😓 } P(y^+|x^+) & \text{VS.} & P(y^-|x^+) \text{ 😊} \\
 \Downarrow & & \Downarrow \\
 \frac{P(x^+|y^+)P(y^+)}{\cancel{P(x^+)}} & \text{VS.} & \frac{P(x^+|y^-)P(y^-)}{\cancel{P(x^+)}} \\
 \Downarrow & & \Downarrow \\
 P(x^+|y^+)P(y^+) & \text{VS.} & P(x^+|y^-)P(y^-)
 \end{array}
 \Rightarrow
 \begin{array}{ccc}
 \text{后验} & & \text{似然} & \text{先验} \\
 \text{(Posterior)} & & \text{(Likelihood)} & \text{(Priors)} \\
 P(Y|X) & \propto & P(X|Y) & P(Y)
 \end{array}$$

$$\text{推断} = \begin{cases} \text{😓 阳性, 若 } P(x^+|y^+)P(y^+) > P(x^+|y^-)P(y^-) \\ \text{😊 阴性, 若 } P(x^+|y^+)P(y^+) \leq P(x^+|y^-)P(y^-) \end{cases}$$

# 朴素贝叶斯决策——一个简单的例子

已知：

- (1) 城市中任意一人，真实患病的概率  $P(y^+) = 0.01$
- (2) 若真实患病，被检测出来患病的概率  $P(x^+|y^+) = 0.9$  ;
- (3) 若没有患病，被检测出来患病的概率  $P(x^+|y^-) = 0.05$  ;

$$\begin{array}{ccc} \text{😓} & P(x^+|y^+)P(y^+) & \text{VS.} & P(x^+|y^-)P(y^-) & \text{😄} \\ & \Downarrow & & \Downarrow & \\ & 0.9 \times 0.01 = 0.009 & < & 0.05 \times (1 - 0.01) = 0.0495 & \end{array}$$

推断：检出阳性，但问题不大 😊

$$\begin{array}{ccc} \text{后验} & \text{似然} & \text{先验} \\ \text{(Posterior)} & \text{(Likelihood)} & \text{(Priors)} \\ P(Y|X) \propto & P(X|Y) & P(Y) \end{array}$$

# 朴素贝叶斯决策——一个简单的例子

已知：

- (1) 城市中任意一人，真实患病的概率  $P(y^+) = 0.1$
- (2) 若真实患病，被检测出来患病的概率  $P(x^+|y^+) = 0.9$  ;
- (3) 若没有患病，被检测出来患病的概率  $P(x^+|y^-) = 0.05$  ;

$$\begin{array}{ccc} \text{😭} P(x^+|y^+)P(y^+) & \text{VS.} & P(x^+|y^-)P(y^-) \text{😄} \\ \Downarrow & & \Downarrow \\ 0.9 \times 0.1 = 0.09 & > & 0.05 \times (1 - 0.1) = 0.045 \end{array}$$

推断：检出阳性，问题很大！ 😭

$$\begin{array}{ccc} \text{后验} & \text{似然} & \text{先验} \\ \text{(Posterior)} & \text{(Likelihood)} & \text{(Priors)} \\ P(Y|X) \propto P(X|Y) P(Y) \end{array}$$

# 贝叶斯法则

## 先验影响推断

$$\begin{array}{c} \text{后验} \\ \text{(Posterior)} \\ P(Y|X) \end{array} = \frac{\begin{array}{c} \text{似然} \\ \text{(Likelihood)} \\ P(X|Y) \end{array} \begin{array}{c} \text{先验} \\ \text{(Priors)} \\ P(Y) \end{array}}{P(X)}$$

➤ 什么是先验 ( Priors ) ?      —————>    期望/想象/信念

- 先验 可以很主观：觉得今天运气特别好，即便知道买彩票是捐赠行为，还是作决定去买
- 先验 可以很客观：某个彩票站开了大奖，即便知道买彩票是捐赠行为，还是作决定去买
- 先验 可以是模型：在DeepSeek的指导下，即便知道买彩票是捐赠行为，还是作决定去买
- 先验 可以是经验：很久没开某个号码了，即便知道买彩票是捐赠行为，还是作决定去买



Rev'd Thomas Bayes (1702–1761)

# 朴素贝叶斯决策——一个简单的例子

已知：

- (1) 城市中任意一人，真实患病的概率  $P(y^+) = 0.01$
- (2) 若真实患病，被检测出来患病的概率  $P(x^+|y^+) = 0.999$  ;
- (3) 若没有患病，被检测出来患病的概率  $P(x^+|y^-) = 0.01$  ;

$$\text{😓 } P(x^+|y^+)P(y^+) \quad \text{VS.} \quad P(x^+|y^-)P(y^-) \quad \text{😊}$$



$$0.999 \times 0.01 = 0.00999 > 0.01 \times (1 - 0.01) = 0.0099$$



推断：检出阳性，问题很大！ 😓

$$\begin{array}{ccc} \text{后验} & \text{似然} & \text{先验} \\ \text{(Posterior)} & \text{(Likelihood)} & \text{(Priors)} \\ P(Y|X) \propto & P(X|Y) & P(Y) \end{array}$$

# 贝叶斯法则

## 似然影响推断

$$\begin{array}{c} \text{后验} \\ \text{(Posterior)} \\ P(Y|X) \end{array} = \frac{\begin{array}{c} \text{似然} \\ \text{(Likelihood)} \\ P(X|Y) \end{array} \begin{array}{c} \text{先验} \\ \text{(Priors)} \\ P(Y) \end{array}}{P(X)}$$

- 什么是先验 ( Priors ) ?  $\longrightarrow$  期望/想象/信念
- 什么是似然 (Likelihood) ?  $\longrightarrow$  观测/证据/度量
- 什么是  $P(X) = \int P(x|y)P(y)dy$  ?  $\longrightarrow$  证据, 模型簇  $Y$  对数据  $X$  的拟合
- 什么是  $P(Y|X)$  ?  $\longrightarrow$  推断/不确定性



Rev'd Thomas Bayes (1702–1761)



# 贝叶斯决策——最小错误率决策



---

贝叶斯最小错误率决策：  $\max_y P(Y|X)$

$$\text{决策规则} = \begin{cases} \text{😓 推断阳性, 若 } \frac{P(x^+|y^+)}{P(x^+|y^-)} > \frac{P(y^+)}{P(y^-)} \\ \text{😊 推断阴性, 若 } \frac{P(x^+|y^+)}{P(x^+|y^-)} \leq \frac{P(y^+)}{P(y^-)} \end{cases}$$

$\underbrace{\frac{P(x^+|y^+)}{P(x^+|y^-)}}_{\text{似然比 } R}$   
(Likelihood Ratio)

# 贝叶斯决策——最小错误率决策



此前随机变量  $X = \{x^+, x^-\}$  表示体温高低，此处令  $X = x$  表示温度数值，即考虑连续情况

# 贝叶斯决策——最小损失决策

---

考虑多分类问题，模型 $f_{\theta}(x)$ ，样本 $x$ 的真实标签为第 $y = j$ 类，被误判为第 $f_{\theta}(x) = i$ 类损失为：

$$\lambda_{ij} = \lambda(f_{\theta}(x) = i | y = j)$$

一般而言，当 $i = j$ 时， $\lambda_{ij} = 0$

➤ 损失函数： $R(f_{\theta}(x)|x) = \sum_i \lambda(f_{\theta}(x)|y = i) p(y = i|x)$

➤ 优化目标： $\min_{\theta} \mathbb{E}(f_{\theta}(x)|x)$

特别地，当 $\lambda_{ij} = 1$ （ $i \neq j$ ）时，最小损失决策与最小错误率决策等效。

➤  $\lambda_{ij}$ 度量了不同决策的后果，如雷达检测敌机、传染病检测等场景需要提高系统灵敏度。

---

# 贝叶斯决策——评价指标

决策 \ 真实状态	阳性	阴性
	阳性	阴性
阳性	真阳 (TP)	假阳 (FP)
阴性	假阴 (FN)	真阴 (TN)

T for True, F for False  
P for Positive, N for Negative

## 两类错误率及评价指标

两类：阳性 (positive)、阴性 (negative)

第一类错误率 (Type-I error rate)  $\frac{FP}{FP+TN}$  误报/虚警

第二类错误率 (Type-II error rate)  $\frac{FN}{FN+TP}$  漏报

灵敏度 (sensitivity)  $S_n = \frac{TP}{TP+FN}$

特异度 (specificity)  $S_p = \frac{TN}{TN+FP}$

# 贝叶斯决策——评价指标

决策 \ 真实状态	阳性	阴性
	阳性	阴性
阳性	真阳 (TP)	假阳 (FP)
阴性	假阴 (FN)	真阴 (TN)

T for True, F for False

P for Positive, N for Negative

其他常用评价指标

正确率 (accuracy)

$$Acc = \frac{TP+TN}{TP+TN+FP+FN}$$

召回率 (recall)

$$Rec = \frac{TP}{TP+FN}$$

灵敏度


准确率 (precision)

$$Pre = \frac{TP}{TP+FP}$$

F度量 (F-measure)

$$F = \frac{2Rec \cdot Pre}{Rec+Pre}$$

# 贝叶斯决策——评价指标



参考博客: <https://mlu-explain.github.io/roc-auc/>

# 贝叶斯决策——推广

---

实际情况比上述“流感问题”复杂得多：

- 多变量
- 多分类
- 多目标
- 连续变量
- 复杂分布
- 带噪数据



$$P(Y|X) = \frac{P(X|Y) P(Y)}{P(X)}$$

$$Y = f_{\theta}(X) \downarrow$$

$$p(\theta|\mathbf{x}) = \frac{p(\mathbf{x}|\theta) p(\theta)}{p(\mathbf{x})}$$

# 贝叶斯参数估计——单维Gaussian估计（ $\mu$ 未知）

---

假设：

- (1)  $p(x|\mu) \sim N(\mu, \sigma^2)$  且  $p(\mu) \sim N(\mu_0, \sigma_0^2)$ ，仅 $\mu$ 未知，要求推断 $\mu$
- (2) 数据集  $\mathcal{X} = \{x_1, \dots, x_n\}$ ，采样独立

$$\max_{\mu} p(\mu|\mathcal{X}) = \frac{p(\mathcal{X}|\mu) p(\mu)}{p(\mathcal{X})} = \alpha \prod_{k=1}^n p(x_k|\mu) p(\mu)$$

$$p(\mu|\mathcal{X}) = \alpha \overbrace{\prod_{k=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{1}{2}\left(\frac{x_k - \mu}{\sigma}\right)^2\right]}^{p(x_k|\mu)} \overbrace{\frac{1}{\sqrt{2\pi}\sigma_0} \exp\left[-\frac{1}{2}\left(\frac{\mu - \mu_0}{\sigma_0}\right)^2\right]}^{p(\mu)}$$

---



# 贝叶斯估计——单维Gaussian估计（ $\mu$ 未知）

---

$$\begin{aligned} p(\mu|\mathcal{X}) &= \alpha \overbrace{\prod_{k=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{1}{2}\left(\frac{x_k - \mu}{\sigma}\right)^2\right]}^{p(x_k|\mu)} \overbrace{\frac{1}{\sqrt{2\pi}\sigma_0} \exp\left[-\frac{1}{2}\left(\frac{\mu - \mu_0}{\sigma_0}\right)^2\right]}^{p(\mu)} \\ &= \alpha' \exp\left[-\frac{1}{2}\left[\sum_{k=1}^n \left(\frac{\mu - x_k}{\sigma}\right)^2 + \left(\frac{\mu - \mu_0}{\sigma_0}\right)^2\right]\right] \\ &= \alpha'' \exp\left[-\frac{1}{2}\left[\left(\frac{n}{\sigma^2} + \frac{1}{\sigma_0^2}\right)\mu^2 - 2\left(\frac{1}{\sigma^2}\sum_{k=1}^n x_k + \frac{\mu_0}{\sigma_0^2}\right)\mu\right]\right] \end{aligned}$$

---

# 贝叶斯估计——单维Gaussian估计（ $\mu$ 未知）

---

$$p(\mu|\mathcal{X}) = \alpha'' \exp \left[ -\frac{1}{2} \left[ \left( \frac{n}{\sigma^2} + \frac{1}{\sigma_0^2} \right) \mu^2 - 2 \left( \frac{1}{\sigma^2} \sum_{k=1}^n x_k + \frac{\mu_0}{\sigma_0^2} \right) \mu \right] \right]$$

$$p(\mu|\mathcal{X}) = \frac{1}{\sqrt{2\pi}\sigma_n} \exp \left[ -\frac{1}{2} \left( \frac{\mu - \mu_n}{\sigma_n} \right)^2 \right]$$

其中:  $\sigma_n^2 = \frac{\sigma_0^2 \sigma^2}{n\sigma_0^2 + \sigma^2}$

$$\mu_n = \left( \frac{n\sigma_0^2}{n\sigma_0^2 + \sigma^2} \right) \bar{x}_n + \frac{\sigma^2}{n\sigma_0^2 + \sigma^2} \mu_0$$

$$\bar{x}_n = \frac{1}{n} \sum_{k=1}^n x_k$$

- 当 $\mu = \mu_n$ 时, 后验概率 $p(\mu|\mathcal{X})$ 取得极大值
- $\sigma_n^2$ 度量了估计的不确定性

# 贝叶斯估计——单维Gaussian估计（ $\mu$ 未知）

---

$$\mu_n = \left( \frac{n\sigma_0^2}{n\sigma_0^2 + \sigma^2} \right) \bar{x}_n + \frac{\sigma^2}{n\sigma_0^2 + \sigma^2} \mu_0$$

- $\mu_n$  是  $\bar{x}_n$  与  $\mu_0$  的线性组合
- 若  $\sigma_0 \neq 0$ ，当  $n \rightarrow \infty$ （更多样本）， $\mu_n \rightarrow \bar{x}_n$
- 若  $\sigma_0 = 0$ ，则  $\mu_n = \mu_0$
- 若  $\sigma_0 \gg \sigma$ ，则  $\mu_n = \bar{x}_n$

# 贝叶斯估计——单维Gaussian估计（ $\mu$ 未知）

---

$$\sigma_n^2 = \frac{\sigma_0^2 \sigma^2}{n\sigma_0^2 + \sigma^2}$$

- 当  $n$  持续增大（样本持续增多）， $\sigma_n^2$  将逼近  $\frac{\sigma^2}{n}$   
（更多的训练样本可以降低对 $\mu$ 估计的不确定性）
- 当  $n$  持续增大（样本持续增多），后验分布 $p(\mu|\mathcal{X})$  变得尖锐  
（方差变小）

# 贝叶斯估计——多维Gaussian估计（ $\mu$ 未知）

---

假设:

- (1)  $p(\mathbf{x}|\mu) \sim N(\mu, \Sigma)$  且  $p(\mu) \sim N(\mu_0, \Sigma_0)$ , 仅  $\mu$  未知, 要求推断  $\mu$
- (2) 数据集  $\mathcal{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_n\}$ , 采样独立

$$\max_{\mu} p(\mu|\mathcal{X}) = \frac{p(\mathcal{X}|\mu) p(\mu)}{p(\mathcal{X})} = \alpha \prod_{k=1}^n p(\mathbf{x}_k|\mu) p(\mu)$$

$$p(\mu|\mathcal{X}) = \alpha \exp\left[-\frac{1}{2}(\mu - \mu_n)^t \Sigma_n^{-1}(\mu - \mu_n)\right]$$

其中:

$$\begin{aligned} \mu_n &= \Sigma_0(\Sigma_0 + \frac{1}{n}\Sigma)^{-1}\bar{\mathbf{x}}_n + \frac{1}{n}\Sigma(\Sigma_0 + \frac{1}{n}\Sigma)^{-1}\mu_0 & \bar{\mathbf{x}}_n &= \frac{1}{n}\sum_{k=1}^n \mathbf{x}_k \\ \Sigma_n &= \Sigma_0(\Sigma_0 + \frac{1}{n}\Sigma)^{-1}\frac{1}{n}\Sigma \end{aligned}$$

---

# 关于Gaussian分布

---

许多同学知道中心极限定理（Central Limit Theorem, CLT）：

令  $\{x_1, \dots, x_n\}$  是从一个总体抽取的独立同分布的随机变量，具有期望值  $\mu$  和方差  $\sigma^2$ ，

当样本量  $n$  足够大时，样本均值  $\bar{x}_n = \frac{1}{n} \sum_{k=1}^n x_k$  的分布会收敛于Gaussian分布：

$$\frac{\bar{x}_n - \mu}{\sigma / \sqrt{n}} \sim N(0, 1)$$

现实意义：

- 许多特征变量分布往往是非Gaussian的，但数据聚合（如均值、加权）后，往往接近Gaussian分布
  - 测试误差往往由多个随机误差叠加，中心极限定理解释了这些误差常常服从Gaussian分布
-

# 关于Gaussian分布

---

还有一个很好的性质， Gaussian分布是最小假设（最大熵假设）

- 熵（Entropy）度量了分布的不确定性：
- 离散情况

$$H(p_1, \dots, p_n) = - \sum_i p_i \log(p_i)$$

- 当 $p_i = \frac{1}{n}$ 时，熵最大（以 $n=2$ 验算一下？）
  - 连续情况：  $h(p(x)) = - \int p(x) \log(p(x)) dx$
  - 对Gaussian分布 $g(x) \sim N(\mu, \sigma^2)$ :  $h(g(x)) = \frac{1}{2} \log(2\pi e \sigma^2)$
-

# 关于Gaussian分布

---

还有一个很好的性质， Gaussian分布是最小假设（最大熵假设）

➤ KL散度（KL Divergence）是对分布之间一致性的度量

➤ 离散情况：  $D_{\text{KL}}(P||Q) = \sum_i \log\left(\frac{p_i}{q_i}\right)p_i$

➤ 连续情况：  $D_{\text{KL}}(p||q) = \int \log\left(\frac{p(x)}{q(x)}\right)p(x)dx$

➤ KL散度的性质：

- 非对称，即  $D_{\text{KL}}(p||q) \neq D_{\text{KL}}(q||p)$ （JS散度具有对称性：  $D_{\text{JS}}(p||q) = \frac{D_{\text{KL}}(p||q) + D_{\text{KL}}(q||p)}{2}$ ）
  - $D_{\text{KL}}(p||q) \geq 0$
  - $D_{\text{KL}}(p||q) = 0$  当且仅当二者分布相同时成立
-



# 关于Gaussian分布

---

还有一个很好的性质， Gaussian分布是最小假设（最大熵假设）

假设：  $p(x)$  是一个均值为  $\mu$ ，方差为  $\sigma^2$  的任意概率分布，

证明：在所有具有相同方差的分布中， Gaussian分布  $q(x)$  的熵最大。

$$D_{\text{KL}}(p||q) = \int \log\left(\frac{p(x)}{q(x)}\right) p(x) dx$$

$$= \int p(x) [\log p(x) - \log q(x)] dx$$

$$= \underbrace{\int p(x) \log p(x) dx}_{-h(p(x))} - \int p(x) \log q(x) dx = -h(p(x)) - \int p(x) \log q(x) dx$$

$$q(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

$$h(q(x)) = \frac{1}{2} \log(2\pi e \sigma^2)$$

# 关于Gaussian分布

---

还有一个很好的性质， Gaussian分布是最小假设（最大熵假设）

假设：  $p(x)$  是一个均值为  $\mu$ ，方差为  $\sigma^2$  的任意概率分布，

证明：在所有具有相同方差的分布中， Gaussian分布  $q(x)$  的熵最大。

$$q(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

$$h(q(x)) = \frac{1}{2} \log(2\pi e \sigma^2)$$

$$D_{\text{KL}}(p||q) = -h(p(x)) - \underbrace{\int p(x) \log q(x) dx}$$

$$= -\frac{1}{2\sigma^2} \int p(x)(x-\mu)^2 dx - \frac{1}{2} \log(2\pi\sigma^2) \quad \int p(x)(x-\mu)^2 dx = \sigma^2$$

$$= -\frac{1}{2} - \frac{1}{2} \log(2\pi\sigma^2)$$

因为  $p(x)$  均值为  $\mu$ ，方差为  $\sigma^2$

# 关于Gaussian分布

---

还有一个很好的性质， Gaussian分布是最小假设（最大熵假设）

假设：  $p(x)$  是一个均值为  $\mu$ ，方差为  $\sigma^2$  的任意概率分布，

证明：在所有具有相同方差的分布中， Gaussian分布  $q(x)$  的熵最大。

$$\begin{aligned} D_{\text{KL}}(p||q) &= -h(p(x)) - \int p(x) \log q(x) dx \\ &= -h(p(x)) + \frac{1}{2} + \frac{1}{2} \log(2\pi\sigma^2) \\ &= -h(p(x)) + h(q(x)) \end{aligned}$$

$$\begin{aligned} q(x) &= \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \\ h(q(x)) &= \frac{1}{2} \log(2\pi e \sigma^2) \end{aligned}$$

因为  $D_{\text{KL}}(p||q) \geq 0$ ，所以  $h(q(x)) \geq h(p(x))$  得证。

---

# 关于Gaussian分布

---

结论—— Gaussian分布的熵最大：在所有具有相同方差的分布中， Gaussian分布的熵最大

这个结果说明了为什么自然界中许多随机变量近似服从Gaussian分布，如：

- 热力学第二定律：封闭系统的熵总是趋向最大化（在热平衡状态下，气体分子速度服从高斯分布）
- 深度神经网络初始化：基于Gaussian分布的Xavier或Kaiming初始化，最大熵分布意味引入最少先验
- 等等。。。

# 今日小结

---

- 贝叶斯法则（后验、似然、先验）
- 最小错误率决策和最小风险决策
- 似然比（N-P决策）
- ROC曲线
- Gaussian分布的点估计
- 中心极限定理、最大熵原理