



深圳大学  
SHENZHEN UNIVERSITY

# 模式识别

## Pattern Recognition

——与计算机视觉  
and Computer Vision

樊超

大数据系统计算技术国家工程实验室@深圳大学

**E-mail:** chaofan996@szu.edu.cn

# 上周回顾：线性判别函数

线性可分训练集： $\{(\mathbf{x}_i, y_i)\}$ ,

其中 $\mathbf{x}_i \in \mathbb{R}^{d \times 1}$ ,  $y_i = \{-1, +1\}$

问题：

寻找分类器 $g(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$ , 要求

$y = +1$ 时 $g(\mathbf{x}) > 0$ ;



$y = -1$ 时 $g(\mathbf{x}) < 0$

$$g(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$$

$$\hat{\mathbf{w}}^T = [b, w_1, \dots]$$


$$\hat{\mathbf{x}} = [1, x_1, \dots]$$

$$g(\mathbf{x}) = \hat{\mathbf{w}}^T \hat{\mathbf{x}}$$




# 支持向量机：动机

---



# 支持向量机：最大间隔思想

---




*The best classifier is the hyperplane with the maximum margin between two classes of data*

V. Vapnik's Principle (1992)

---


# 支持向量机：最大间隔目标



$$\max_{w, b, \gamma} 2\gamma$$

$$\begin{aligned} \text{s. t. } & \frac{w^T x_i + b}{\|w\|_2} \geq \gamma \quad \forall i, y_i = 1 \\ & \frac{w^T x_i + b}{\|w\|_2} \leq -\gamma \quad \forall i, y_i = -1 \end{aligned}$$

# 支持向量机：最大间隔目标



$$\begin{aligned} \max_{\mathbf{w}, b, \gamma} \quad & 2\gamma \\ \text{s.t.} \quad & y_i \frac{\mathbf{w}^T \mathbf{x}_i + b}{\|\mathbf{w}\|_2} \geq \gamma \end{aligned}$$

# 支持向量机：最大间隔目标

---



$$\begin{array}{ccc} \max_{\mathbf{w}, b, \gamma} 2\gamma & \Rightarrow & \max_{\mathbf{w}, b, \gamma} 2\gamma \\ s. t. \quad y_i \frac{\mathbf{w}^T \mathbf{x}_i + b}{\|\mathbf{w}\|_2} \geq \gamma & & y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 \\ & & \|\mathbf{w}\|_2 \gamma = 1 \end{array} \Rightarrow \max_{\mathbf{w}, b} \frac{2}{\|\mathbf{w}\|_2} \quad y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1$$

# 支持向量机：最大间隔目标

$$\max_{\mathbf{w}, b} \frac{2}{\|\mathbf{w}\|_2}$$

$$s.t. \quad y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1$$

几何解释



$$H_1: \mathbf{w}^T \mathbf{x} + b = 1$$

$$H_2: \mathbf{w}^T \mathbf{x} + b = -1$$




# 支持向量机：最大间隔目标

---

$$\max_{\mathbf{w}, b} \frac{2}{\|\mathbf{w}\|_2}$$

$s.t. \quad y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1$




$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|_2$$

$s.t. \quad y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1$

常见形式

# 支持向量机：算一个简单例子！

---



已知如图数据集，  
试求最大间隔SVM  $(\mathbf{w}, b)$ .

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|_2$$

$$s. t. \quad y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1$$

# 支持向量机：学习的对偶算法

---

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|_2^2 \\ \text{s.t.} \quad & y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 \end{aligned}$$

⇓ 构造拉格朗日函数


$$\begin{aligned} L(\mathbf{w}, b, \alpha) = & \frac{1}{2} \|\mathbf{w}\|_2^2 - \sum_i \alpha_i (y_i(\mathbf{w}^T \mathbf{x}_i + b) - 1) \\ \text{s.t.} \quad & \alpha_i \geq 0 \end{aligned}$$

# 支持向量机：学习的对偶算法

---

原问题

$$\begin{aligned} \min_{\mathbf{w}} \quad & \frac{1}{2} \|\mathbf{w}\|_2^2 \\ \text{s.t.} \quad & y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 \end{aligned}$$



对偶问题

$$\begin{aligned} \max_{\alpha} \quad & \min_{\mathbf{w}, b} L(\mathbf{w}, b, \alpha) \\ \text{s.t.} \quad & \alpha_i \geq 0 \end{aligned}$$

# 支持向量机：学习的对偶算法

---

$$\begin{aligned} \max_{\alpha} \min_{\mathbf{w}, b} L(\mathbf{w}, b, \alpha) &= \frac{1}{2} \|\mathbf{w}\|_2 - \sum_i \alpha_i (y_i(\mathbf{w}^T \mathbf{x}_i + b) - 1) \\ s.t. \quad \alpha_i &\geq 0 \end{aligned}$$

- 若满足原问题的约束条件（红色虚线框），则  $\alpha_i \rightarrow 0$ ，即对偶问题等价于原问题
- 否则， $\alpha_i \rightarrow +\infty$ ，即无解

# 支持向量机：学习的对偶算法

---

$$\begin{aligned} \max_{\alpha} \min_{\mathbf{w}, b} L(\mathbf{w}, b, \alpha) &= \frac{1}{2} \|\mathbf{w}\|_2 - \sum_i \alpha_i (y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1) \\ \text{s.t. } \alpha_i &\geq 0 \end{aligned}$$

(1) 先求  $\min_{\mathbf{w}, b} L(\mathbf{w}, b, \alpha)$

$$\text{令 } \nabla_{\mathbf{w}} L(\mathbf{w}, b, \alpha) = \mathbf{w} - \sum_i \alpha_i y_i \mathbf{x}_i = 0 \quad \Rightarrow \quad \mathbf{w} = \sum_i \alpha_i y_i \mathbf{x}_i$$

$$\text{令 } \nabla_b L(\mathbf{w}, b, \alpha) = \sum_i \alpha_i y_i = 0$$

# 支持向量机：学习的对偶算法

---

$$\begin{aligned} \max_{\alpha} \min_{\mathbf{w}, b} L(\mathbf{w}, b, \alpha) &= \frac{1}{2} \|\mathbf{w}\|_2 - \sum_i \alpha_i (y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1) \\ \text{s.t. } \alpha_i &\geq 0 \end{aligned}$$

(2) 再求  $\max_{\alpha} \min_{\mathbf{w}, b} L(\mathbf{w}, b, \alpha)$

$$L(\mathbf{w}, b, \alpha) = \frac{1}{2} \|\mathbf{w}\|_2 - \sum_i \alpha_i (y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1)$$

$$\begin{aligned} &= \frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j - \sum_i \alpha_i (y_i (\sum_j \alpha_j y_j \mathbf{x}_j^T \mathbf{x}_i + b) - 1) \\ &= -\frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j + \sum_i \alpha_i \end{aligned}$$

$$\begin{aligned} \mathbf{w} &= \sum_i \alpha_i y_i \mathbf{x}_i \\ \sum_i \alpha_i y_i &= 0 \end{aligned}$$

# 支持向量机：学习的对偶算法

---

$$\begin{aligned} \max_{\alpha} \min_{\mathbf{w}, b} L(\mathbf{w}, b, \alpha) &= \frac{1}{2} \|\mathbf{w}\|_2 - \sum_i \alpha_i (y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1) \\ \text{s.t. } \alpha_i &\geq 0 \end{aligned}$$

(2) 再求  $\max_{\alpha} \min_{\mathbf{w}, b} L(\mathbf{w}, b, \alpha)$

$$\begin{aligned} \max_{\alpha} & -\frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j + \sum_i \alpha_i \\ \text{s.t. } & \sum_i \alpha_i y_i = 0, \quad \alpha_i \geq 0 \end{aligned}$$

---



# 支持向量机：学习的对偶算法

---

$$\begin{aligned} \max_{\alpha} \min_{\mathbf{w}, b} L(\mathbf{w}, b, \alpha) &= \frac{1}{2} \|\mathbf{w}\|_2 - \sum_i \alpha_i (y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1) \\ s.t. \quad \alpha_i &\geq 0 \end{aligned}$$

(2) 再求  $\max_{\alpha} \min_{\mathbf{w}, b} L(\mathbf{w}, b, \alpha)$

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j - \sum_i \alpha_i \\ s.t. \quad & \sum_i \alpha_i y_i = 0, \quad \alpha_i \geq 0 \end{aligned}$$

# 支持向量机：学习的对偶算法

---

$$\begin{aligned} \max_{\alpha} \min_{\mathbf{w}, b} L(\mathbf{w}, b, \alpha) &= \frac{1}{2} \|\mathbf{w}\|_2 - \sum_i \alpha_i (y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1) \\ \text{s.t. } \alpha_i &\geq 0 \end{aligned}$$

(3) 最后找 $\mathbf{w}^*$ 和 $b^*$


令(2)中解为 $\alpha^*$ ，则：

$$\begin{aligned} \mathbf{w}^* &= \sum_i \alpha_i^* y_i \mathbf{x}_i \\ b^* &= y_j - \sum_i \alpha_i^* y_i (\mathbf{x}_i^T \mathbf{x}_j) \end{aligned}$$

---

# 支持向量机：再算一下那个例子！

---



已知如图数据集，

试求最大间隔SVM  $(\mathbf{w}, b)$ .

$$\min_{\alpha} \frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j - \sum_i \alpha_i$$
$$s. t. \sum_i \alpha_i y_i = 0, \quad \alpha_i \geq 0$$

# 支持向量机：学习的对偶算法

KKT ( Kuhn-Tucker ) 条件:

$$\alpha_i(y_i(\mathbf{w}^T \mathbf{x}_i + b)) - 1 = 0$$


- $y_i(\mathbf{w}^T \mathbf{x}_i + b) > 1$ , 则  $\alpha_i = 0$ ,

此时  $\mathbf{x}_i$  远离决策面, 不对发挥作用

- $y_i(\mathbf{w}^T \mathbf{x}_i + b) = 1$ , 则  $\alpha_i > 0$ ,

此时  $\mathbf{x}_i$  位于决策面上, 直接决定决策面,

此时称  $\mathbf{x}_i$  为支持向量



$$H_1: \mathbf{w}^T \mathbf{x} + b = 1$$

$$H_2: \mathbf{w}^T \mathbf{x} + b = -1$$

# 支持向量机：学习的对偶算法

---

SVM的分类判别函数：

$$\begin{aligned} & \max_{\alpha} \min_{\mathbf{w}, b} L(\mathbf{w}, b, \alpha) \\ & \text{s.t. } \alpha_i \geq 0 \end{aligned} \quad \Rightarrow \quad \begin{aligned} \mathbf{w}^* &= \sum_i \alpha_i^* y_i \mathbf{x}_i \\ b^* &= y_j - \sum_i \alpha_i^* y_i (\mathbf{x}_i^T \mathbf{x}_j) \\ g(\mathbf{x}) &= \sum_i \alpha_i^* \mathbf{x}_i^T \mathbf{x} + b^* \end{aligned}$$

与数据点的内积紧密相关！

---

# 松弛条件下的支持向量机

**Hard** Margin

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|_2$$

s. t.

$$y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1$$

**Soft** Margin

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|_2 + C \sum_i \xi_i$$


s. t.

$$y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i$$

$$\xi_i \geq 0$$

$\xi_i$  : 松弛变量 (容忍限度, 越大, 则边界更宽松)

$C$  : 惩罚系数 (容忍意志, 越大, 则越不能容忍)



$$H_1: \mathbf{w}^T \mathbf{x} + b = 1$$


$$H_i: \mathbf{w}^T \mathbf{x} + b = 1 - \xi_i$$

$$H_2: \mathbf{w}^T \mathbf{x} + b = -1$$

# 松弛条件下的支持向量机：学习的对偶算法

---

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|_2 + C \sum_i \xi_i \\ \text{s.t.} \quad & y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i \\ & \xi_i \geq 0 \end{aligned}$$



构造拉格朗日函数


$$\begin{aligned} L(\mathbf{w}, b, \xi, \alpha, \mu) = & \frac{1}{2} \|\mathbf{w}\|_2 + C \sum_i \xi_i - \sum_i \alpha_i (y_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 + \xi_i) - \mu_i \sum_i \xi_i \\ \text{s.t.} \quad & \alpha_i \geq 0, \quad \mu_i \geq 0 \end{aligned}$$

---

# 松弛条件下的支持向量机：学习的对偶算法

$$\max_{\alpha, \mu} \min_{\mathbf{w}, b, \xi} L(\mathbf{w}, b, \xi, \alpha, \mu) = \frac{1}{2} \|\mathbf{w}\|_2 + C \sum_i \xi_i - \sum_i \alpha_i (y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1 + \xi_i) - \mu_i \sum_i \xi_i$$

$$s.t. \alpha_i \geq 0, \quad \mu_i \geq 0$$




$$\text{令 } \nabla_{\mathbf{w}} L(\mathbf{w}, b, \xi, \alpha, \mu) = 0$$

$$\text{令 } \nabla_b L(\mathbf{w}, b, \xi, \alpha, \mu) = 0$$

$$\text{令 } \nabla_{\xi} L(\mathbf{w}, b, \xi, \alpha, \mu) = 0$$

$$\min_{\alpha} \frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j - \sum_i \alpha_i$$

$$s.t. \sum_i \alpha_i y_i = 0, \quad 0 \leq \alpha_i \leq C$$



$$\begin{aligned} \mathbf{w}^* &= \sum_i \alpha_i^* y_i \mathbf{x}_i \\ b^* &= y_j - \sum_i \alpha_i^* y_i (\mathbf{x}_i^T \mathbf{x}_j) \end{aligned}$$



# 松弛条件下的支持向量机：学习的对偶算法

KKT ( Kuhn-Tucker ) 条件:

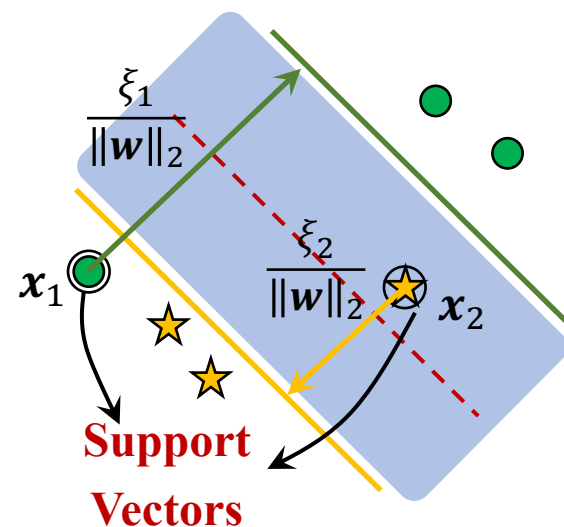
$$\alpha_i(y_i(\mathbf{w}^T \mathbf{x}_i + b)) - 1 + \xi_i = 0$$

- $0 < \alpha_i < C$ , 则  $\xi_i = 0$ ,

此时  $\mathbf{x}_i$  为正确分类的支撑向量 (位于决策边界)


- $\alpha_i = C$ , 则  $\xi_i > 0$ ,

此时  $\mathbf{x}_i$  为错误分类的支撑向量




# 线性不可分条件下的支持向量机

---



# 线性不可分条件下的支持向量机：核技巧

核心思路：低维不可分，则映射至高维试试



# 线性不可分条件下的支持向量机：核技巧

---

学习的对偶算法

$$g(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b \quad \Rightarrow \quad g(\mathbf{x}) = \sum_i \alpha_i^* \mathbf{x}_i^T \mathbf{x} + b^*$$

核技巧  $\phi$

$$g(\mathbf{x}) = \mathbf{w}^T \phi(\mathbf{x}) + b \quad \Rightarrow \quad g(\mathbf{x}) = \sum_i \alpha_i^* \boxed{\phi(\mathbf{x}_i^T) \phi(\mathbf{x})} + b^*$$

核函数：无需显式的  $\phi$ ，直接定义内积  $\mathcal{K}$ ，避免（a）低维向高维投射的计算开销；（b）无限维的特征空间无法映射


$$\mathcal{K}(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i) \phi(\mathbf{x}_j)$$

# 线性不可分条件下的支持向量机：核技巧

显式映射  $\phi(\cdot)$


VS.

核技巧  $\mathcal{K}(\cdot, \cdot)$




第一步：2D 到 6D

$$\phi(\mathbf{x}) = \phi\left(\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}\right) = \begin{bmatrix} 1, \\ \sqrt{2}x_1, \\ \sqrt{2}x_2, \\ x_1^2, \\ x_2^2, \\ \sqrt{2}x_1x_2 \end{bmatrix} \quad \phi(\mathbf{y}) = \phi\left(\begin{bmatrix} y_1 \\ y_2 \end{bmatrix}\right) = \begin{bmatrix} 1, \\ \sqrt{2}y_1, \\ \sqrt{2}y_2, \\ y_1^2, \\ y_2^2, \\ \sqrt{2}y_1y_2 \end{bmatrix}$$



第二步：算内积

$$\phi(\mathbf{x})^T \phi(\mathbf{y}) = (1 + x_1y_1 + x_2y_2)^2$$



直接定义  
一步到位

$$\mathcal{K}(\mathbf{x}, \mathbf{y}) = (1 + x_1y_1 + x_2y_2)^2$$

# 线性不可分条件下的支持向量机：核技巧

---

几个常见核函数

$$\mathcal{K}(\mathbf{x}_1, \mathbf{x}_2) = \mathbf{x}_1^T \mathbf{x}_2$$

线性核

$$\mathcal{K}(\mathbf{x}_1, \mathbf{x}_2) = \mathbf{x}_1^T \Sigma^{-1} \mathbf{x}_2 \quad (\Sigma^{-1} \text{ 为正定矩阵})$$

$$\mathcal{K}(\mathbf{x}_1, \mathbf{x}_2) = (\mathbf{x}_1^T \mathbf{x}_2 + 1)^d$$

多项式核


$$\mathcal{K}(\mathbf{x}_1, \mathbf{x}_2) = \exp(-\|\mathbf{x}_1 - \mathbf{x}_2\|_2^2 / 2\sigma^2)$$

Gaussian核

# 线性不可分条件下的支持向量机

---

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j \mathcal{K}(\mathbf{x}_i, \mathbf{x}_j) - \sum_i \alpha_i \\ \text{s.t.} \quad & \sum_i \alpha_i y_i = 0, \quad 0 \leq \alpha_i \leq C \end{aligned}$$



$$g(\mathbf{x}) = \sum_i \alpha_i^* \mathcal{K}(\mathbf{x}_i, \mathbf{x}) + b^*$$


# 支持向量机：再回顾

---

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|_2 + C \sum_i \xi_i$$

$$\begin{aligned} s.t. \quad & y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i \\ & \xi_i \geq 0 \end{aligned}$$

等价



$$\min_{\mathbf{w}, b} \overset{\text{正则项}}{\lambda \|\mathbf{w}\|_2} + \sum_i \overset{\text{经验损失}}{[1 - y_i(\mathbf{w}^T \mathbf{x}_i + b)]_+}$$

其中：

$$[z]_+ = \begin{cases} z, & z > 0 \\ 0, & z \leq 0 \end{cases}$$



# 支持向量机：优化算法

---


经典的序列最小化最优化（Sequential Minimal Optimization, SMO）

同时，可以用梯度下降法：

$$\min_{\mathbf{w}, b} L(\mathbf{w}, b) = \frac{1}{2} \|\mathbf{w}\|_2 + C \sum_i [1 - y_i(\mathbf{w}^T \mathbf{x}_i + b)]_+$$

$$\nabla_{\mathbf{w}} L_i = \begin{cases} \mathbf{w} - Cy_i \mathbf{x}_i, & \text{若 } 1 - y_i(\mathbf{w}^T \mathbf{x}_i + b) > 0 \\ \mathbf{w}, & \text{否则} \end{cases}$$

$$\nabla_b L_i = \begin{cases} -Cy_i, & \text{若 } 1 - y_i(\mathbf{w}^T \mathbf{x}_i + b) > 0 \\ 0, & \text{否则} \end{cases}$$



---

大小为  $N$  的数据集  $\{(\mathbf{x}_i, y_i)\}$ ,  
随机初始  $\mathbf{w}$ ,  $b$ , 总迭代次数  $E$

for  $e$  in range( $E$ ):

    for  $i$  in range( $N$ ):

        if  $1 - y_i(\mathbf{w}^T \mathbf{x}_i + b) > 0$ :

$\mathbf{w} \leftarrow \mathbf{w} - \eta \nabla_{\mathbf{w}} L_i$

$b \leftarrow b - \eta \nabla_b L_i$

    return  $\mathbf{w}, b$

---